

1. Contexte et objectif

Le fichier initial **stats.csv** contient **300 lignes** (100 départements × 3 années : 2021, 2022, 2023) et **30 colonnes** de données issues de l'INSEE, du RPLS et de la CDC Habitat.

L'objectif de l'épuration est de ne conserver que les colonnes **pertinentes pour la DataViz**, en se basant sur la liste fournie dans les consignes de la SAé (section « Mise en place du projet »). Le fichier épuré passe de **30 à 17 colonnes**, soit 13 colonnes supprimées.

Fichier initial 30 colonnes	Conservées 17 colonnes	Supprimées 13 colonnes
--	---	---

2. Colonnes conservées (17)

Ces colonnes correspondent à celles explicitement listées dans les consignes de la SAé. Elles couvrent quatre axes d'analyse : identification géographique, démographie, indicateurs socio-économiques et logement.

Colonne	Justification de la conservation
année_publication	Identifiant temporel indispensable pour filtrer et comparer les données sur les 3 années (2021-2023). Nécessaire pour les graphes d'évolution.
code_departement	Identifiant unique de chaque département. Utile pour les jointures en base de données et pour la partie back-end Symfony.
nom_departement	Lisible par l'humain, indispensable pour l'affichage dans les graphes Chart.JS et l'interface front-end Angular.
nom_region	Permet de regrouper les départements par région pour des analyses agrégées (graphes par région, filtres régionaux).
Nombre d'habitants	Donnée démographique fondamentale. Permet de contextualiser le nombre de logements sociaux par rapport à la population.
Densité de population au km²	Indicateur de pression urbaine. Les zones denses ont des besoins en logement social différents des zones rurales.
Variation de la population sur 10 ans (%)	Mesure l'attractivité ou le déclin d'un territoire. Impact direct sur la demande en logements.
Dont contribution du solde naturel (%)	Détaille la part de la variation liée aux naissances/décès. Utile pour comprendre les dynamiques démographiques.
Dont contribution du solde migratoire (%)	Détaille la part de la variation liée aux migrations. Indicateur clé de l'attractivité territoriale.
% population de moins de 20 ans	Proxy pour la catégorie de population demandée dans les consignes. Indicateur de jeunesse du territoire.

% population de 60 ans et plus	Complément du précédent. Important car le vieillissement impacte les besoins en logement adapté.
Taux de chômage au T4 (%)	Indicateur socio-économique majeur. Corrélié directement avec la demande de logement social.
Taux de pauvreté (%)	Directement lié aux besoins en logement social. Permet d'identifier les territoires les plus fragiles.
Nombre de logements	Volume total du parc de logements. Base de calcul pour les ratios et les graphes.
Nombre de résidences principales	Sous-ensemble du parc utilisé comme habitation principale. Utile pour calculer des taux d'occupation.
Taux de logements sociaux (%)	Donnée centrale du projet. C'est l'indicateur principal à visualiser et analyser.
Taux de logements vacants (%)	Indicateur de tension du marché. Un taux élevé peut signaler un déséquilibre offre/demande.

Ces colonnes ont été retirées car elles ne figurent pas dans la liste des données demandées par les consignes, ou parce qu'elles sont redondantes avec une colonne déjà conservée.

Colonne supprimée	Raison de la suppression
code_region	Redondant avec nom_region qui est déjà conservé. Le code numérique n'apporte aucune valeur pour la DataViz ni pour l'utilisateur final.
Taux de logements individuels (%)	Non listé dans les consignes. Concerne la typologie des logements (maison vs appartement), ce qui est hors périmètre de l'analyse du logement social.
Moyenne annuelle de la construction neuve sur 10 ans	Non listé dans les consignes. Porte sur la construction générale, pas spécifiquement sur le logement social.
Construction	Non listé dans les consignes. Donnée brute de construction qui fait doublon avec la moyenne annuelle, sans lien direct avec le logement social.
Parc social - Nombre de logements	Non listé dans les consignes. Niveau de détail opérationnel sur la gestion du parc social, alors que le projet vise des analyses macro.
Parc social - Logements mis en location	Non listé dans les consignes. Donnée de flux (entrées dans le parc) qui relève de la gestion opérationnelle.
Parc social - Logements démolis	Non listé dans les consignes. Information sur les sorties du parc, non nécessaire pour l'analyse décisionnelle visée.
Parc social - Ventes à des personnes physiques	Non listé dans les consignes. Concerne les cessions de logements sociaux, hors périmètre d'analyse.
Parc social - Taux de logements vacants (%)	Non listé dans les consignes. On conserve déjà le taux de logements vacants global, celui-ci est spécifique au parc social.

Parc social - Taux de logements individuels (%)	Non listé dans les consignes. Typologie interne au parc social, non pertinente pour les analyses demandées.
Parc social - Loyer moyen (€/m²/mois)	Non listé dans les consignes. Donnée intéressante mais hors du périmètre défini par les consignes du projet.
Parc social - Âge moyen du parc (en années)	Non listé dans les consignes. Indicateur de vétusté qui relève de la gestion patrimoniale, pas de l'analyse décisionnelle.
Parc social - Taux de logements énergivores (E,F,G) (%)	Non listé dans les consignes. De plus, cette colonne contient 13 valeurs manquantes (4.3%), ce qui poserait des problèmes d'analyse.